

数据分析线上实习项目：信贷违约预测模型

项目背景

金融科技行业飞速发展，信贷业务作为核心业务之一，面临着日益增长的风险管理挑战。传统的信贷审批流程依赖人工经验和规则判断，效率有限且难以应对复杂多变的信用风险。本项目旨在构建一个基于机器学习的信贷违约预测模型，通过分析用户的历史数据和行为特征，预测其违约概率，为金融机构的风控决策提供数据支持。

项目计划

项目总览

阶段	主题	核心任务	详细任务描述	技术能力要求
1	项目启动与数据探索	1. 环境搭建与数据获取 2. 初步数据分析	• 建立Python数据分析环境 • 下载并加载数据集 • 理解数据字典与业务背景 • 数据概览与质量检查	Python环境配置、Pandas基础、数据理解
2	数据预处理	1. 数据清洗 2. 探索性分析 (EDA)	• 处理缺失值、异常值、重复值 • 单变量与多变量分析 • 目标变量分布分析 • 数据可视化	数据清洗技巧、Matplotlib/Seaborn可视化
3	特征工程	1. 特征编码与变换 2. 特征选择	• 类别变量编码(独热、标签) • 数值特征标准化/归一化 • 特征组合与交互项 • 特征相关性分析	Scikit-learn预处理、特征工程方法
4	模型构建与评估	1. 基础模型训练 2. 模型性能比较	• 逻辑回归、随机森林、XGBoost模型训练 • 验证集性能评估 • 多指标比较分析	机器学习模型、模型评估指标
5	模型优化	1. 超参数调优 2. 模型集成	• 网格搜索/随机搜索调参 • 交叉验证 • 模型集成策略	超参数优化、交叉验证、集成学习
6	结果总结与报告	1. 模型部署与测试 2. 项目总结	• 测试集最终评估 • 业务解读与建议 • 项目报告撰写	模型部署、业务沟通、文档撰写

详细计划

第1阶段：项目启动与数据探索

- 任务1.1：环境搭建（Python 3.8+，Jupyter Notebook，必要库安装）
- 任务1.2：数据加载与初步探索（数据形状、数据类型、缺失值统计）

- **任务1.3:** 业务理解与问题定义（明确预测目标与评估标准）
- **交付物:** 项目环境配置文档、数据探索报告

第2阶段：数据预处理

- **任务2.1:** 缺失值处理（删除、填充策略选择与实现）
- **任务2.2:** 异常值检测与处理（箱线图、 3σ 原则、业务规则）
- **任务2.3:** 重复值处理与数据一致性检查
- **任务2.4:** 探索性数据分析（分布分析、相关性初步分析）
- **交付物:** 数据清洗代码、EDA可视化报告

第3阶段：特征工程

- **任务3.1:** 类别特征编码（独热编码、标签编码、目标编码）
- **任务3.2:** 数值特征标准化/归一化（标准化、最小最大归一化）
- **任务3.3:** 特征创建（组合特征、分箱、多项式特征）
- **任务3.4:** 特征选择（过滤法、包装法、嵌入法）
- **交付物:** 特征工程代码、特征重要性分析

第4阶段：模型构建与评估

- **任务4.1:** 数据集划分（训练集70%、验证集20%、测试集10%）
- **任务4.2:** 基础模型训练（逻辑回归、随机森林、XGBoost）
- **任务4.3:** 模型性能评估（准确率、精确率、召回率、F1、AUC-ROC）
- **任务4.4:** 模型对比分析与初步解释
- **交付物:** 模型训练代码、验证集性能对比表

第5阶段：模型优化

- **任务5.1:** 超参数调优（网格搜索、随机搜索、贝叶斯优化）
- **任务5.2:** 交叉验证策略（K折交叉验证）
- **任务5.3:** 模型集成（投票法、堆叠法）
- **任务5.4:** 调优后模型再训练与评估
- **交付物:** 调优参数记录、优化后模型性能

第6阶段：结果总结与报告

- **任务6.1:** 测试集最终评估与模型泛化能力分析
- **任务6.2:** 业务解读（关键特征分析、风险阈值选择）
- **任务6.3:** 模型局限性分析与改进建议
- **任务6.4:** 项目报告撰写与可视化展示
- **交付物:** 最终项目报告、可视化仪表板、项目演示PPT

交付物

1. 代码文件

- `data_preprocessing.py` - 数据预处理完整流程
- `feature_engineering.py` - 特征工程实现
- `model_training.py` - 模型训练与评估代码
- `model_optimization.py` - 模型优化与调参代码
- `main_pipeline.ipynb` - 完整项目流程Jupyter Notebook

2. 分析报告

- 数据探索报告：包含数据质量分析、分布可视化
- 特征工程报告：特征处理策略与选择依据
- 模型评估报告：各模型性能对比与详细分析
- 最终项目报告：完整项目总结，包含业务建议（10-15页）

3. 可视化成果

- EDA可视化：数据分布、相关性热力图、特征重要性图
- 模型性能可视化：ROC曲线、PR曲线、混淆矩阵、学习曲线
- 业务仪表盘：使用Plotly/Dash或Streamlit构建简单交互式仪表盘

4. 项目文档

- `README.md` - 项目概述与运行指南
- `requirements.txt` - 项目依赖包列表
- `presentation.pptx` - 项目汇报演示文稿（10-15页）

技术栈

核心工具与库

- 编程语言：Python 3.8+
- 数据分析：Pandas, NumPy
- 数据可视化：Matplotlib, Seaborn, Plotly
- 机器学习：Scikit-learn, XGBoost, LightGBM
- 模型解释：SHAP, ELI5
- 开发环境：Jupyter Notebook, VS Code
- 版本控制：Git, GitHub/GitLab

8. 可选: FastAPI/Flask (模型API部署), Docker (容器化)

关键技术点

- 数据清洗: 缺失值处理、异常值检测、数据标准化
- 特征工程: 编码技术、特征缩放、特征选择方法
- 机器学习模型: 逻辑回归、决策树、随机森林、梯度提升树
- 模型评估: 分类指标、交叉验证、学习曲线
- 模型优化: 超参数调优、集成学习、模型解释

参考资料

1. 数据集

- 阿里天池信贷违约数据集: <https://tianchi.aliyun.com/dataset/140861>
- 备用数据集: Kaggle信用评分数据集 <https://www.kaggle.com/datasets/laotse/credit-risk-dataset>

2. 技术教程

- Scikit-learn官方教程: <https://scikit-learn.org/>
- 特征工程全面指南: <https://www.kaggle.com/learn/feature-engineering>
- 机器学习模型解释: <https://christophm.github.io/interpretable-ml-book/>

3. 理论知识

- 信贷风控基础知识:
 - 《Credit Risk Scorecards》
 - 《Credit Scoring, Response Modeling and Insurance Rating》
- 机器学习在金融中的应用:
 - 《Machine Learning for Financial Risk Management with Python》
 - 《Risk Modeling - Practical Applications of Artificial Intelligence, Machine Learning, and Deep Learning》

4. 实践案例

- Kaggle竞赛案例: Home Credit Default Risk
 - <https://www.kaggle.com/competitions/home-credit-default-risk>
- 天池竞赛案例: <https://tianchi.aliyun.com/competition/entrance/531830/introduction>

5. 工具与库文档

- **Pandas**官方文档: <https://pandas.pydata.org/docs/>
- **Matplotlib**教程: <https://matplotlib.org/stable/tutorials/index.html>
- **XGBoost**文档: <https://xgboost.readthedocs.io/en/stable/>

6. 在线学习平台

- **Coursera**: Applied Data Science with Python专项课程
- **DataCamp**: Machine Learning for Finance专项课程