

第一阶段实验报告：项目启动与初步数据探索

一. 实验背景

本项目主题为信贷违约预测，目标是基于借款人的贷款信息，信用信息和历史行为特征，预测用户是否可能发生违约，为后续信贷风控建模提供基础。

本阶段属于项目第一阶段，主要目标是项目启动，数据读取，基础数据概览，目标变量确认和数据质量初步检查。为下一阶段数据清洗和 EDA 做准备。

二. 实验目标

- 使用 Python 和 Jupyter Notebook 读取本地数据文件。
- 查看数据形状, 字段信息和基础统计结果。
- 检查缺失值情况，识别后续需要重点处理的字段。
- 初步区分数值字段和类别/非数值字段。
- 基于项目目标和字段名称，检查可能的目标变量 `isDefault`。
- 检查重复行和 `id` 唯一性，为后续建模准备数据理解基础。

三. 使用工具

- Python
- Jupyter Notebook
- Pandas
- Git / GitHub

本阶段主要使用 Pandas 完成数据读取和基础统计。

四. 数据读取方式

Notebook 使用相对路径读取数据文件，避免硬编码本机绝对路径。当前读取文件为 `credit_data.csv`。

完整数据文件未上传至 GitHub，原因是文件体积较大，不适合直接纳入普通 Git 版本管理。

五. 实验过程与结果

1. 数据基础概览

指标	结果
样本数量	800,000
字段数量	47

数据共包含 800,000 条样本和 47 个字段，数据规模较大，适合后续进行机器学习建模和风险特征分析。

2. 字段类型概览

字段类型	数量
float64	33
int64	9
str	5

按照 Pandas 识别的数据类型，数值字段共有 42 个，非数值字段共有 5 个。该划分只是第一阶段的初步检查，后续仍需要结合业务含义逐个判断字段是否保留以及如何处理。

3. 缺失值检查

字段	缺失数量	缺失比例
n11	69,752	8.72%
employmentLength	46,799	5.85%
n8	40,271	5.03%
n6	40,270	5.03%
n12	40,270	5.03%
n9	40,270	5.03%
n13	40,270	5.03%
n14	40,270	5.03%
n5	40,270	5.03%
n0	40,270	5.03%

缺失值主要集中在 n11, employmentLength 以及多个 n 系列字段。第二阶段需要结合字段含义了解缺失值是否有实际意义，并结合缺失比例制定处理策略，如填充,或在必要时删除字段或者样本。

4. 目标变量检查

isDefault	样本数量	占比
0	640,390	80.05%
1	159,610	19.95%

从项目目标和字段名称判断，isDefault 可能是本项目的目标变量。但当前项目文件中未提供字段说明，因此后续仍需结合参考资料进一步确认。该字段取值为 0 和 1，分别表示未违约和违约，因此本项目属于二分类问题。

当前违约样本占比约为 19.95%，未违约样本占比约为 80.05%，存在一定类别不平衡。后续模型评估时不应只看准确率，还应关注召回率,精确率,F1 值和 AUC 等指标。

5. 重复值与 ID 检查

检查项	结果
重复行数量	0
id 是否唯一	是

当前数据未发现完全重复行，之后不需要删除重复数据，且 id 字段唯一，说明每条记录可以通过 id 区分。后续建模时 id 通常只作为样本标识，不作为预测特征使用。

六. 阶段性结论

- 当前 Notebook 覆盖了第一阶段所需的核心代码，包括数据读取,基础概览,缺失值检查,目标变量检查和重复值检查。
- 数据规模较大，满足后续建模分析需要。
- isDefault 很可能是目标变量，任务类型应为二分类任务。
- 数据存在一定类别不平衡，后续模型评估需要使用多种分类指标。
- 缺失值主要集中在部分 n 系列字段和 employmentLength 字段，需要在第二阶段重点处理。
- 当前阶段还没有进行正式数据清洗,特征编码和模型训练，这些内容应放在后续阶段。

七. 下一阶段计划

- 基于参考资料中的数据集和理论知识进一步确认字段含义。
- 制定缺失值处理策略。
- 检查异常值和不合理取值。
- 对类别变量进行编码准备。
- 开展更完整的 EDA，包括变量分布,变量与目标变量关系和可视化分析。
- 为后续特征工程和模型训练准备清洗后的数据。

八. 阶段产出

- data_preprocessing.ipynb: 第一阶段代码
- 第一阶段实验报告.pdf: 第一阶段实验报告