

第二阶段实验报告：数据清洗与探索性数据分析

信贷违约预测项目

一. 实验背景

本项目以信贷违约预测为目标，使用借款人的贷款信息、信用信息和历史行为特征预测是否发生违约。第一阶段完成了数据读取、字段概览、目标变量确认和初步数据质量检查；第二阶段在此基础上实施数据清洗、数据一致性检查和探索性数据分析，为后续特征工程、数据划分和模型训练准备可靠的数据基础。

二. 实验目标

- 在不覆盖原始 CSV 的前提下创建独立清洗副本。
- 处理重复记录和已确认的非匿名字段缺失值。
- 依据字段定义检测业务逻辑异常，并区分错误值与具有业务意义的统计极端值。
- 检查字符串、等级、工作年限和日期字段的一致性。
- 保存清洗后的完整数据集。
- 完成目标变量、数值字段、类别字段、匿名字段及时间趋势的 EDA。
- 分析不同类型特征与目标变量 isDefault 之间的统计关联。

三. 使用工具

- Python：数据处理与统计分析。
- Jupyter Notebook：记录清洗过程、分析代码和可视化结果。
- Pandas、NumPy：数据清洗、分组统计和一致性检查。
- Matplotlib、Seaborn：数据分布及变量关系可视化。
- Git / GitHub：项目代码与报告版本管理；大体积 CSV 仅保存在本地。

四. 数据与处理原则

原始数据 `credit_data.csv` 包含 800,000 条样本和 47 个字段。Notebook 使用相对路径读取数据，并通过 `df.copy()` 创建 `df_clean`，所有清洗操作只作用于副本。清洗后的数据保存为 `credit_data_cleaned.csv`，未覆盖原始文件。

本阶段遵循“有明确依据才处理”的原则：违反字段定义的业务逻辑异常可以删除；IQR 边界外的统计极端值不自动等同于错误值。对于业务含义未知的匿名字段 n0–n14，保留原始缺失值，仅检查非缺失值是否满足非负整数规则。

五. 数据清洗过程与结果

1. 重复值处理

原始数据未发现完全重复记录，删除重复记录数量为 0；id 保持唯一，可作为样本标识，但后续不应作为预测特征。代码中仍保留删除重复记录的步骤，是为了保证清洗流程的可复用性；后续如果更换或追加新数据，可以直接使用同一段代码检查并删除重复样本。

2. 缺失值处理

字段	处理方法	处理结果或原因
employmentTitle、 postCode、title	删除缺失记录	各缺失 1 条，缺失数量极少
revolUtil、 pubRecBankruptcies、dti	删除缺失记录	与前三个字段合计影响 1,177 条不同记录
employmentLength	填充 Unknown	清洗过程中 46,538 条记录保留为独立类别
n0–n14	保留 NaN	缺失原因和业务含义未知，不进行主观插补

清洗后除 n0–n14 外，其他字段不存在缺失值。匿名字段仍保留 612,517 个缺失单元格，后续可结合缺失指示变量和模型验证决定处理方式。

3. 业务逻辑异常处理

按照字段定义对全部数值字段进行覆盖式检查，包括正数、非负数、整数、编码范围和字段间逻辑关系。检测到 2 条 dti=-1 记录。dti 表示债务收入比，不应为负数，因此删除这 2 条记录。处理后再次运行相同规则，未发现剩余的已确认业务逻辑异常。

4. 统计极端值处理

对 14 个主要数值字段使用 IQR 方法统计极端值。delinquency_2years、pubRec 和 pubRecBankruptcies 的 0 值占比超过 75%，导致 Q1 和 Q3 均为 0，因此其 IQR 结果不用于删除。dti 及其他字段的极端值可能具有真实风险识别意义，予以保留。

字段	Q1	Q3	IQR 下界	IQR 上界	删除记录数	处理后最大值
revolUtil	33.5	70.7	-22.3	126.5	47	126.4

本阶段仅按 IQR 边界删除 47 条 revolUtil 极端值。revolUtil 表示循环额度利用率，该字段在清洗前的 Q1 为 33.5、Q3 为 70.7，IQR 上界为 126.5，但实际最大值达到 892.3，与上界相差过大，明显偏离该字段的大部分样本分布，因此将超过 IQR 上界的记录作为异常极端值删除；处理后 revolUtil 最大值为 126.4。正式划分训练集和测试集后，这类由数据计算得到的边界应只在训练集上重新估计，再应用于验证集或测试集，以避免数据泄漏。

5. 字符串与日期一致性检查

对 grade、subGrade、employmentLength、issueDate 和 earliesCreditLine 检查空字符串、首尾空格和预期格式；同时检查 subGrade 首字母与 grade 是否一致、issueDate 是否为每月 1 日、最早信用额度开立月份是否晚于贷款发放月份。所有检查的异常数量均为 0，因此不修改原始字符串。issueDate 的原始格式为 YYYY-MM-DD，earliesCreditLine 的原始格式为月份缩写-年份，两者表示的业务含义不同：前者是贷款发放月份，后者是最早信用额度开立月份。本阶段的目标是清洗和一致性检查，所以只验证两个字段各自格式是否稳定，以及时间先后关系是否合理，不强行把两个日期字段统一成同一种格式；日期拆分、统一日期类型、计算信用历史长度等处理留到后续特征工程阶段。

6. 清洗结果汇总

指标	结果
原始数据形状	800,000 × 47
删除重复记录	0
删除指定缺失记录	1,177
删除负数 dti 记录	2
删除 revolUtil 极端值记录	47
共删除记录	1,226 (约 0.153%)
清洗后数据形状	798,774 × 47

六. 探索性数据分析

1. 目标变量分布

isDefault	样本数量	占比
0 (未违约)	639,420	80.05%
1 (违约)	159,354	19.95%




图 1 清洗后目标变量分布

清洗后违约样本占 19.95%，未违约样本占 80.05%，类别比例与原始数据基本一致。后续模型评估不能只使用准确率，还应关注 AUC、召回率、精确率和 F1 值，并在数据划分时采用分层抽样或时间划分。

2. 单变量分布

主要数值字段使用全部清洗样本绘图。annualIncome、dti 和 revolBal 呈明显右侧长尾，少数极大值会把大部分样本挤在图的左侧，因此仅在绘图时使用 log1p 压缩横轴尺度，方便观察主体样本的分布形态；log1p 表示 $\log(1+x)$ ，可以处理取值为 0 的情况。delinquency_2years、pubRec 和 pubRecBankruptcies 保留原始计数值，但由于 0 和小计数样本占绝大多数，高计数样本频数很低，因此使用对数频数轴显示低频高值，避免这些尾部取值在图中完全看不见。以上处理只用于可视化展

示，不改变清洗后的原始字段取值，也不代表在建模阶段已经完成特征变换。类别字段使用频数柱状图，数值编码只作为类别标签，不解释为连续大小关系。

匿名计数特征 n0–n14 分别统计缺失比例、唯一值数量、最小值、最大值和零值比例。n11 缺失比例最高，为 8.67%；多数匿名字段缺失比例约为 4.98%。n11、n12 和 n13 的零值高度集中，因此分布图使用对数纵轴，但不改变字段原始取值。




图 2 主要数值字段单变量分布

从图 2 可以看出，主要数值字段的分布形态差异较明显。loanAmnt 主要集中在 8,000 到 20,000 附近，installment 主要集中在几百元区间，interestRate 主要集中在中等利率区间；annualIncome、dti 和 revolBal 右侧长尾明显，说明大多数样本集中在较低或中等水平，少数样本取值很高。delinquency_2years、pubRec 和 pubRecBankruptcies 以 0 和小计数为主，说明多数借款人在这些负面记录字段上的次数较少。revolUtil 在清洗后主要分布在 0 到 100 附近，仍保留较宽分布，但已经去除与 IQR 上界差距过大的异常极端记录。



图 3 类别与离散字段单变量分布

从图 3 可以看出，类别与离散字段的单变量分布是通过多个柱状图展示的：每个小图对应一个字段，横轴表示该字段的不同类别或编码取值，纵轴表示每个类别对应的样本数量。因此，这张图主要说明样本在不同类别之间是如何分布的，而不是说明违约率或字段与目标变量的关系。具体来看，term 中 3 年期样本明显多于 5 年期；grade 主要集中在 B、C、A、D 等级，E、F、G 样本较少；employmentLength 中 10+ years 样本最多，说明当前样本中长期就业借款人占比较高，但不能简单概括为工作时间越长贷款越多，因为其他年限类别并不是严格递增。purpose 和 regionCode 也存在明显集中类别，但由于编码含义不完整，本阶段只观察频数分布，不直接做业务解释。




图 4 匿名计数特征单变量分布

从图 4 可以看出，匿名计数特征 n0-n14 的非缺失值多数呈现右偏或零值集中的计数型分布。很多字段在较小取值处样本最多，随着取值增大，样本数量快速减少，因此使用对数纵轴才能看到尾部低频取值。n11、n12、n13 等字段的低取值集中更明显，说明这些匿名行为计数字段并不是均匀分布的。由于这些字段缺少具体业务含义，本阶段不根据图形结果主观删除或填补，只保留其分布特征供后续特征工程和模型验证使用。

3. 主要数值字段与目标变量

字段	Spearman 相关系数
interestRate	0.2546
ficoRangeLow	-0.1306

ficoRangeHigh	-0.1306
dti	0.1060
loanAmnt	0.0705
annualIncome	-0.0673
installment	0.0596
revolUtil	0.0590




图 5 主要数值字段与目标变量的 Spearman 相关系数

interestRate 与违约状态的 Spearman 相关系数最高，为 0.2546，表现为正向单调关系；ficoRangeLow 和 ficoRangeHigh 均为-0.1306，表现为负向关系；dti 为 0.1060。其他主要数值字段的相关系数绝对值均低于 0.1。相关系数只反映单调关系，因此 Notebook 同时使用分组违约率图检查可能的非线性变化。




图 6 主要数值字段分组违约率

从图 6 可以看出，主要数值字段分组后的违约率变化可以补充 Spearman 相关系数无法体现的非线性关系。interestRate 分组越高，违约率整体上升，说明高利率样本在当前数据中违约比例更高；FICO 区间越高，违约率整体下降，符合信用评级越高风险越低的直观理解；dti、loanAmnt 和 revolUtil 也呈现较明显的分组差异，其中 dti 和 revolUtil 较高区间的违约率整体更高。该图只能说明当前样本中的统计关系，仍需在后续模型中验证这些关系是否稳定。

4. 类别字段与目标变量




图 7 贷款等级、期限与违约率

字段	类别	样本数量	违约率
term	3 年	605,882	16.00%
term	5 年	192,892	32.36%
grade	A	139,493	6.04%
grade	G	5,354	49.72%
subGrade	A1	25,890	3.19%
subGrade	G5	643	55.05%
employmentLength	Unknown	46,538	26.90%
applicationType	1	15,145	25.20%

贷款等级、子等级和期限的不同类别之间存在明显违约率差异。employmentLength=Unknown 组的违约率高于 10+ years 组，说明工作年限缺失状态可能具有预测信息。对于 homeOwnership、purpose、regionCode 等编码字段，由于缺少编码映射，只报告类别间差异，不推断具体业务含义。样本量很少的类别也不能仅凭高违约率判定为稳定高风险类别。



图 8 类别字段分组违约率

从图 8 可以看出，不同类别字段取值下的违约率存在明显差异。grade 和 subGrade 的违约率随等级变差而上升，A 等级最低、G 等级最高；term 为 5 年的样本违约率明显高于 3 年；employmentLength 中的 Unknown 组违约率较高，说明工作年限缺失状态本身可能携带风险信息。purpose、regionCode 等编码字段的不同编码组之间也有违约率差异，但因为缺少完整业务映射，只能说明存在统计差异，暂不做具体业务解释。

5. 匿名字段与目标变量

字段	Spearman 相关系数
n14	0.0858
n3	0.0686
n2	0.0686
n9	0.0668
n1	0.0381
n7	0.0319

n10	0.0249
n5	-0.0208




图9 匿名字段相关性与缺失状态违约率

匿名字段中绝对相关性最高的是 n14 (0.0858) ， 其次为 n3 和 n2 (均为 0.0686) 以及 n9 (0.0668) 。所有匿名字段的相关系数绝对值均低于 0.1， 未表现出明显的单变量单调相关性。

除 n11 外， 多数匿名字段的缺失样本违约率约为 14.89%， 非缺失样本约为 20.22%； n11 缺失组约为 20.20%， 非缺失组约为 19.93%。这说明部分匿名字段的缺失模式可能携带信息， 但由于多个字段可能共同缺失， 且缺失机制未知， 不能据此解释原因或直接决定填补方式。




图 10 匿名字段非缺失值分组违约率

从图 10 可以看出，匿名字段非缺失取值分组后，部分字段在不同取值区间上存在违约率差异。例如 n14、n3、n2、n9 等字段随着取值区间增大，违约率整体有上升趋势，这与它们在 Spearman 相关系数中相对靠前一致。但并非所有匿名字段都呈现稳定单调关系，部分字段曲线波动较大，可能受样本量、缺失机制和字段含义未知的影响。因此匿名字段不能只凭单变量图判断价值，后续应结合缺失指示变量、类别化处理和模型验证来决定使用方式。

6. 放款月份与违约率




图 11 放款月份样本量与违约率变化

指标	结果
时间范围	2007-08 至 2018-12
月份数量	135
最少月样本数	1
最多月样本数	29,038

数据早期部分月份的样本量仅为 1 至数条，对应违约率只能出现 0、1 或其他剧烈波动，因此这些月份不能用于判断稳定时间趋势。后续若采用时间划分，还需要结合样本量、贷款观察窗口和数据来源判断是否存在时间偏移。

七. 阶段性结论

- 第二阶段完成了重复值、缺失值、业务逻辑异常、统计极端值以及字符串和日期一致性检查。
- 清洗后保留 798,774 条样本和全部 47 个字段，删除比例约为 0.153%，目标变量比例基本保持不变。

- 匿名字段的缺失值被保留，避免在缺少业务含义时进行主观插补。
- interestRate、FICO 区间和 dti 与违约状态表现出相对更明显的单调关联。
- grade、subGrade 和 term 的类别间违约率差异明显，具有后续建模价值。
- 匿名字段的单变量 Spearman 相关性整体较弱，但缺失状态、非线性关系和组合预测价值仍需模型验证。
- 统计极端值可能对应真实高风险借款人，除 revolUtil 的已确认极端记录外未进行批量删除。

八. 分析局限

- 当前阶段的 EDA 主要用于理解完整清洗数据的整体结构和变量关系，尚未进入正式建模流程；后续进行特征工程和模型训练时，应先划分训练集、验证集和测试集，并仅在训练集上拟合插补、编码和异常边界等处理规则。
- 部分编码字段缺少数据字典，匿名字段也缺少具体业务含义，因此当前只能描述统计差异，不能解释编码对应的业务类别、匿名字段缺失机制或业务因果关系。

九. 下一阶段计划

- 特征工程和建模前数据准备。
- 结合数据来源和数据字典进一步确认字段含义及编码映射，明确哪些字段可直接使用、哪些字段需要转换或舍弃。
- 确定训练集、验证集和测试集划分方案；后续所有由数据计算得到的处理规则都应只在训练集上拟合，再应用于验证集和测试集。
- 开展特征工程，包括日期字段拆分、信用历史长度计算、employmentLength 数值化及缺失指示变量构造。
- 制定类别字段和高基数字段的处理策略，包括 grade、subGrade、purpose、regionCode、employmentTitle、postCode 和 title 等字段的编码方式。
- 评估匿名字段 n0–n14 的缺失指示变量、保留方式和必要的变换方式，并产出可用于后续建模的特征数据集和字段处理说明。

十. 阶段产出

- data_preprocessing.ipynb：第一阶段概览及第二阶段清洗与 EDA 代码。
- credit_data_cleaned.csv：本地保存的清洗后数据，不上传 GitHub。
- 第二阶段实验报告.docx：第二阶段实验过程、结果与结论。